

Evaluasi Keterbatasan YOLOv8n pada Deteksi Objek Kecil Berkelompok melalui Peningkatan Resolusi Input

Bhima Fairul Rifqi
NIM 26/579939/PPA/07301
Magister Kecerdasan Artifisial
Departemen Ilmu Komputer dan Elektronika
Fakultas Matematika dan Ilmu Pengetahuan Alam
Universitas Gadjah Mada
bhimafairulrifqi@mail.ugm.ac.id

Ringkasan—YOLO diperkenalkan sebagai *single-stage object detector* yang memprediksi *bounding box* dan probabilitas kelas secara langsung dari citra, sehingga mampu melakukan deteksi secara cepat. Namun, Redmon dkk. melaporkan bahwa YOLO generasi awal memiliki keterbatasan dalam melokalisasi objek kecil, khususnya ketika objek muncul secara berkelompok. Penelitian ini menguji apakah fenomena tersebut masih terlihat pada YOLO modern menggunakan YOLOv8n dan dataset Global Wheat Detection. Dua konfigurasi dibandingkan dengan parameter pelatihan yang sama, yaitu resolusi input 640×640 sebagai *baseline* dan 1024×1024 sebagai intervensi. Evaluasi dilakukan menggunakan mAP@0.5, mAP@0.5:0.95, AP berdasarkan ukuran objek, serta waktu inferensi. Resolusi 1024 meningkatkan mAP@0.5:0.95 dari 0,5295 menjadi 0,5429 dan AP *small* dari 0,1330 menjadi 0,1461. Meskipun meningkat, AP *small* masih jauh lebih rendah dibanding AP *medium* dan *large*. Waktu inferensi juga meningkat dari 17,12 menjadi 20,16 ms/citra. Hasil menunjukkan bahwa peningkatan resolusi dapat mengurangi, tetapi belum menghilangkan, kesulitan YOLO modern dalam mendeteksi objek kecil.

Kata kunci—YOLOv8, small object detection, input resolution, Global Wheat Detection, mAP.

I. PENDAHULUAN

Object detection merupakan tugas *computer vision* untuk menentukan kategori dan lokasi objek dalam citra menggunakan *bounding box*. Pendekatan *two-stage* seperti R-CNN [4], [5] memisahkan proses pencarian kandidat wilayah dan klasifikasi, sedangkan pendekatan *one-stage* melakukan prediksi secara langsung sehingga umumnya lebih sederhana dan cepat. YOLO merupakan salah satu pendekatan *one-stage* yang paling banyak dikembangkan karena menggabungkan prediksi lokasi dan kelas dalam satu proses. Varghese dan Sambath [3] juga menempatkan YOLO sebagai keluarga *detector* yang menonjol karena kombinasi kecepatan dan akurasi untuk aplikasi *real-time*.

Redmon dkk. [1] memperkenalkan YOLO dengan merumuskan *object detection* sebagai masalah regresi dari keseluruhan citra langsung menuju *bounding box* dan probabilitas kelas. Model dasar YOLO pada paper awal berjalan pada 45 FPS, sementara Fast YOLO mencapai 155 FPS. Akan tetapi,

keuntungan kecepatan tersebut disertai kesalahan lokalisasi yang lebih tinggi dibanding beberapa *detector* lain.

Salah satu keterbatasan utama YOLOv1 adalah deteksi objek kecil yang berdekatan. Pada arsitektur awal, batasan spasial grid membatasi jumlah objek yang dapat diprediksi pada satu area. Redmon dkk. secara eksplisit menyebut bahwa model kesulitan terhadap objek kecil yang muncul dalam kelompok. Selain itu, proses *downsampling* menghasilkan fitur yang relatif kasar dan kesalahan posisi kecil memiliki dampak IoU lebih besar pada *bounding box* kecil [1].

Arsitektur YOLO telah berkembang sejak temuan tersebut. YOLOv8 yang diperkenalkan Ultralytics pada 2023 menggunakan pendekatan *anchor-free* dan mendukung berbagai tugas *computer vision* [2]. Analisis source code oleh Hidayatullah dkk. [2] menunjukkan bahwa YOLOv8 menggunakan blok C2f, SPPF untuk representasi multi-skala, proses *upsampling* dan *concatenation* pada *neck*, serta tiga *detection head* yang menangani objek relatif kecil, medium, dan besar. Meskipun demikian, tantangan *small-object detection* tetap relevan; literatur YOLOv8 juga menekankan kebutuhan pengujian performa berdasarkan skala objek [3]. Berdasarkan hal tersebut, penelitian ini menguji pertanyaan:

“Apakah peningkatan resolusi input dari 640×640 menjadi 1024×1024 meningkatkan performa YOLOv8n, khususnya pada objek kecil dan berkelompok?”

Eksperimen menggunakan Global Wheat Detection dan membandingkan dua konfigurasi YOLOv8n secara terkontrol. Kontribusi utama penelitian adalah evaluasi ulang fenomena *small-object limitation* pada YOLO modern, pengujian resolusi sebagai intervensi, serta analisis performa berdasarkan ukuran objek dan *failure cases*.

II. TINJAUAN PUSTAKA

A. YOLO dan Keterbatasan Objek Kecil

YOLOv1 membagi citra menjadi grid $S \times S$, kemudian setiap sel bertanggung jawab terhadap objek yang pusatnya

berada pada sel tersebut. Setiap sel memprediksi *bounding box*, *confidence*, dan probabilitas kelas. Pada PASCAL VOC, konfigurasi awal menghasilkan tensor prediksi $7 \times 7 \times 30$ [1].

Desain tersebut memungkinkan deteksi dilakukan dalam satu evaluasi jaringan, tetapi juga menimbulkan batasan spasial. Redmon dkk. melaporkan bahwa YOLO kesulitan pada objek kecil berkelompok serta bahwa sumber kesalahan utamanya berkaitan dengan lokalisasi [1]. Pada evaluasi VOC 2012, YOLO juga dilaporkan lebih lemah pada beberapa kategori berukuran kecil dibanding *detector* pesaing [1].

B. YOLOv8

YOLOv8 merupakan perkembangan modern dari keluarga YOLO yang diperkenalkan Ultralytics pada 2023. Hidayatullah dkk. [2] menyebut YOLOv8 menggunakan pendekatan *anchor-free*, yang menyederhanakan mekanisme deteksi dibanding pendekatan berbasis *anchor*.

Secara umum, arsitektur YOLO terdiri atas *backbone*, *neck*, dan *head*. *Backbone* mengekstraksi fitur pada beberapa resolusi, *neck* mengintegrasikan fitur multi-skala melalui operasi seperti *upsampling* dan *concatenation*, sedangkan *head* menghasilkan prediksi objek [2]. Pada YOLOv8, blok utama yang digunakan adalah C2f. Setelah *backbone* terdapat SPPF (*Spatial Pyramid Pooling Fast*) untuk menangkap representasi fitur pada beberapa skala [2].


YOLOv8 mempunyai tiga *detection head*. Head pertama menangani objek yang relatif kecil terhadap frame, head kedua objek medium, dan head ketiga objek besar [2]. Desain *multi-scale* tersebut secara teoritis lebih sesuai untuk variasi ukuran objek dibanding grid tunggal YOLOv1. Namun keberadaan head khusus objek kecil tidak otomatis berarti masalah *small-object detection* telah sepenuhnya teratasi.

Varghese dan Sambath [3] juga menekankan evaluasi berdasarkan ukuran objek, yaitu *small*, *medium*, dan *large*, sebagai cara untuk melihat perubahan performa pada skala berbeda. Prinsip tersebut menjadi dasar evaluasi eksperimen ini.

III. METODOLOGI

A. Dataset

Dataset yang digunakan adalah Global Wheat Detection, yang berisi citra kepala gandum dengan anotasi *bounding box*. Dataset yang diproses memiliki 3.373 citra dan 147.793 anotasi, atau rata-rata sekitar 43,82 objek per citra. Kepadatan tersebut membuat dataset relevan untuk menguji kondisi objek yang muncul berkelompok.



Gambar 1. Distribusi Ukuran Objek.

Data dibagi dengan rasio 80:20 menggunakan *random seed* 42 sehingga diperoleh 2.698 citra *training* dan 675 citra *validation*. Anotasi dikonversi dari format $[x, y, w, h]$ menjadi format YOLO yang dinormalisasi.

Ukuran objek mengikuti kategori COCO:

- **small:** $\text{area} < 32^2$
- **medium:** $32^2 \leq \text{area} < 96^2$
- **large:** $\text{area} \geq 96^2$

Distribusi menghasilkan 1.287 objek *small* (0,87%), 117.135 *medium* (79,26%), dan 29.371 *large* (19,87%). Karena kategori *small* merupakan bagian kecil dari dataset, hasil AP *small* perlu diinterpretasikan dengan hati-hati.

B. Model dan Eksperimen

Model yang digunakan adalah YOLOv8n *pretrained COCO* dari Ultralytics. Varian nano dipilih karena memberikan konfigurasi ringan sehingga eksperimen resolusi tinggi tetap dapat dijalankan pada GPU yang tersedia.

Dua eksperimen dilakukan dengan konfigurasi sama kecuali resolusi input.

Tabel I
KONFIGURASI EKSPERIMEN

Parameter	Baseline	Intervensi
Model	YOLOv8n	YOLOv8n
Input	640 × 640	1024 × 1024
Epoch	15	15
Batch	16	16
Seed	42	42
Train/Val	2698/675	2698/675

Resolusi 640 digunakan sebagai *baseline* standar, sedangkan 1024 merupakan intervensi. Karena citra asli berukuran 1024×1024 , konfigurasi kedua mempertahankan lebih banyak detail spasial.

C. Evaluasi

Evaluasi utama dilakukan dengan COCOeval menggunakan mAP@0.5, mAP@0.5:0.95, serta AP *small*, *medium*, dan *large*. Pemisahan berdasarkan ukuran penting karena mAP keseluruhan dapat menyembunyikan kelemahan pada objek kecil. Pendekatan evaluasi lintas skala juga ditekankan dalam studi YOLOv8 yang menggunakan kategori objek *small*, *medium*, dan *large* [3].

Waktu inferensi per citra diukur pada subset *validation* yang sama. Selain evaluasi kuantitatif, tiga citra padat dianalisis untuk membandingkan jumlah *true positive* pada IoU 0,5.


IV. HASIL

Tabel II
HASIL EVALUASI

Metrik	640	1024	Δ
mAP@0.5	0,9218	0,9306	+0,0088
mAP@0.5:0.95	0,5295	0,5429	+0,0134
AP small	0,1330	0,1461	+0,0131
AP medium	0,5228	0,5376	+0,0149
AP large	0,5767	0,5814	+0,0046
Inferensi (ms)	17,12	20,16	+3,04

Peningkatan resolusi memberikan kenaikan pada seluruh metrik AP. mAP@0.5:0.95 meningkat dari 0,5295 menjadi 0,5429. AP *small* meningkat dari 0,1330 menjadi 0,1461 atau sekitar 9,8% secara relatif terhadap *baseline*. AP *medium* meningkat 0,0149, sedangkan perubahan AP *large* hanya 0,0046.

Average Recall *small* juga meningkat dari 0,212 menjadi 0,260. Walaupun demikian, AP *small* pada kedua konfigurasi tetap jauh di bawah *medium* dan *large*.



Gambar 2. Grafik Perbandingan AP Small, Medium, dan Large.

Waktu inferensi naik dari 17,12 menjadi 20,16 ms/citra, atau sekitar 17,8%. Dengan demikian, peningkatan resolusi memberikan keuntungan akurasi dengan biaya komputasi tambahan.

V. PEMBAHASAN

A. Keterbatasan Objek Kecil pada YOLO Modern

Hasil menunjukkan bahwa fenomena yang dilaporkan Redmon dkk. [1] masih dapat diamati pada YOLOv8n. Pada resolusi 640, AP *small* hanya 0,1330, dibanding AP *medium* 0,5228 dan AP *large* 0,5767. Bahkan setelah resolusi dinaikkan menjadi 1024, AP *small* hanya meningkat menjadi 0,1461.

Temuan ini tidak berarti bahwa mekanisme penyebab pada YOLOv8 sama dengan YOLOv1. YOLOv1 menggunakan batasan grid yang berbeda, sedangkan YOLOv8 telah menggunakan desain *anchor-free*, *feature fusion* multi-skala, SPPF, serta tiga *detection head* [2]. Meskipun arsitekturnya telah berkembang, objek kecil tetap menghasilkan performa lebih rendah daripada objek medium dan besar.

Dengan demikian, klaim Redmon dkk. lebih tepat dinilai sebagai masih berlaku pada tingkat fenomena, bukan pada mekanisme arsitektural yang identik.


B. Pengaruh Resolusi Input

Intervensi 1024 meningkatkan mAP@0.5:0.95 sebesar 0,0134 dan AP *small* sebesar 0,0131. Peningkatan AR *small* dari 0,212 menjadi 0,260 juga menunjukkan bahwa model dengan resolusi lebih tinggi mampu menemukan lebih banyak objek kecil.

Penjelasan yang paling masuk akal adalah bahwa *resizing* ke 640 mengurangi jumlah piksel yang merepresentasikan setiap kepala gandum. Ketika ukuran input 1024 dipertahankan, detail spasial yang tersedia pada *feature map* awal lebih besar sebelum mengalami proses *downsampling*. Hal ini relevan dengan struktur YOLOv8 yang menggunakan beberapa *stride-2 convolution* sehingga resolusi fitur berkurang bertahap [2].

Namun peningkatan tersebut relatif kecil secara absolut dan tidak menghapus selisih antara AP *small* dan kategori lainnya. Jadi resolusi tinggi merupakan mitigasi, bukan solusi penuh.

C. Failure Case



Gambar 3. Visualisasi Perbandingan Ground Truth, YOLOv8n 640, dan YOLOv8n 1024 pada Failure Case.

Pada tiga citra padat, hasil TP@0.5 adalah:

- 71 GT: 68 TP pada 640 dan 67 TP pada 1024;
- 70 GT: 65 TP pada 640 dan 66 TP pada 1024;
- 68 GT: 61 TP pada kedua konfigurasi.

Hasil tersebut menunjukkan bahwa 1024 tidak selalu lebih baik pada setiap citra. Pada salah satu kasus TP meningkat, satu kasus tetap, dan satu kasus justru turun. Karena itu, kegagalan pada kondisi padat tidak dapat dijelaskan oleh resolusi saja. *Overlap* objek, *confidence*, kualitas lokalisasi, dan *post-processing* juga berpotensi berpengaruh.

Observasi ini konsisten dengan *error analysis* YOLOv1 yang menemukan bahwa *incorrect localization* merupakan sumber kesalahan utama model [1].

D. Trade-off dan Keterbatasan

Resolusi 1024 memberikan performa lebih tinggi, tetapi waktu inferensi meningkat sekitar 17,8%. Hal ini mempertahankan karakteristik umum YOLO sebagai model yang perlu menyeimbangkan akurasi dan efisiensi. Literatur YOLOv8 juga menempatkan kecepatan komputasi sebagai aspek penting dalam mengevaluasi *detector real-time* [3].

Eksperimen memiliki tiga keterbatasan. Pertama, hanya 0,87% anotasi termasuk kategori *small* menurut definisi COCO. Kedua, hanya YOLOv8n dan satu intervensi yang diuji. Ketiga, pelatihan dibatasi 15 epoch untuk menjaga eksperimen tetap terkontrol dan terjangkau secara komputasi. Eksperimen lanjutan dapat membandingkan resolusi tinggi dengan *image tiling*, yang memungkinkan objek kecil diperbesar secara lokal.

VI. KESIMPULAN

Eksperimen menunjukkan bahwa keterbatasan deteksi objek kecil yang dikemukakan Redmon dkk. masih dapat diamati pada YOLOv8n, meskipun arsitektur modern telah menggunakan pendekatan *anchor-free*, *feature fusion* multi-skala, dan *detection head* khusus untuk ukuran objek berbeda. AP *small* tetap jauh lebih rendah daripada AP *medium* dan *large*.

Peningkatan resolusi dari 640×640 menjadi 1024×1024 meningkatkan mAP@0.5:0.95 dari 0,5295 menjadi 0,5429 dan AP *small* dari 0,1330 menjadi 0,1461. Namun waktu inferensi meningkat dari 17,12 menjadi 20,16 ms/citra. Dengan demikian, peningkatan resolusi memitigasi tetapi belum menghilangkan masalah *small-object detection* dan menghasilkan *trade-off* antara akurasi dan efisiensi.

PUSTAKA

- [1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 779–788.
- [2] P. Hidayatullah, N. Syakrani, M. R. Sholahuddin, T. Gelar, and R. Tubagus, "YOLOv8 to YOLO11: A Comprehensive Architecture In-depth Comparative Review," 2026.
- [3] R. Varghese and M. Sambath, "YOLOv8: A Novel Object Detection Algorithm with Enhanced Performance and Robustness," in *2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS)*, 2024, doi: 10.1109/ADICS58448.2024.10533619.
- [4] R. Girshick, "Fast R-CNN," in *IEEE International Conference on Computer Vision (ICCV)*, 2015.
- [5] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," *IEEE Trans. Pattern Anal. Mach. Intell.*, 2015.
- [6] D. Hoiem, Y. Chodpathumwan, and Q. Dai, "Diagnosing Error in Object Detectors," in *European Conference on Computer Vision (ECCV)*, 2012.
- [7] M. Everingham et al., "The Pascal Visual Object Classes Challenge: A Retrospective," *Int. J. Comput. Vis.*, vol. 111, no. 1, pp. 98–136, 2015.